



Anti-Spam Bot

Benutzeranleitung

Für Server-Mitglieder, Moderation und Admins

1. Was ist der Anti-Spam Bot?

Der Anti-Spam Bot prüft Nachrichten, die er auf dem Server sehen darf. Er erkennt wiederholten Text und einfache Spam-Muster, meldet Verdachtsfälle und kann Nachrichten löschen oder Mitglieder vorübergehend stummschalten. **Kick und Ban führt er niemals automatisch aus.**

Wichtig: Ein Verdachtsfall ist kein Beweis für Betrug. Der Bot kann schon vor einer Mod-Entscheidung löschen oder einen Timeout setzen. Kick und Ban entscheiden ausschließlich berechnete Moderierende.

2. Wie erkennt der Bot Spam?

Methode 1 – Neues Account-Alter:

Ein Discord-Konto unter **4 Tagen** erhält die Einstufung **Risiko: Hoch**. Das Konto-Alter allein erzeugt **keine** Meldung und löscht keine Nachricht.

Methode 2 – Gleiche Nachricht mehrfach:

In der aktuellen Projekt-.env lösen **3 gleiche Nachrichten in 15 Minuten** aus. Ohne Eintrag gilt der Programmstandard 4.

Methode 3 – Einfache Keyword-Muster:

Bei **ML_SPAM_DETECTION=true** erkennt der Wortfilter **free**, **click**, **discord.gg** und **bit.ly**. Schon **free-test-123** kann auslösen. Es ist kein trainiertes ML-Modell.

Risiko-Übersicht:

Situation	Risiko	Bot-Reaktion im aktiven Modus
Neues Konto, normale Nachricht	Hoch	Keine Maßnahme allein wegen des Alters.
3 gleiche Nachrichten in 15 Min.	Normal / Hoch	Verdachtsfall; Löschen, wenn aktiviert, und Mod-Meldung.
Ein einzelner Keyword-Treffer	Normal / Hoch	Verdachtsfall; auch diese einzelne Nachricht kann gelöscht werden.
Normale einmalige Nachricht	Normal	Keine Anti-Spam-Reaktion.

3. Was passiert, wenn Spam erkannt wird?

Schritt 1 – Protokollieren und ggf. Löschen

Der Bot speichert einen Verdachtsfall mit Fall-ID. Im Modus „Aktiv“ und bei **SPAM_DELETE=true** versucht er die Nachricht zu löschen. Bei Wiederholungen sucht er auch gleiche Nachrichten aus den letzten 30 Minuten.

Schritt 2 – Mod-Benachrichtigung

Im privaten Mod-Kanal erscheinen Konto, Risiko, Nachrichtenausschnitt und Fall-ID. Meldungen zum selben Text werden normalerweise zwei Minuten gedrosselt; das erstmalige Erreichen der Wiederholungsschwelle löst dennoch erneut aus.

Schritt 3 – Mod-Buttons

Unter der Meldung stehen **Timeout, Kick, Ban und Fehlalarm**. Der Bot prüft die Discord-Rechte der klickenden Person. Bei Sanktionen gelten zusätzlich die Rollen-Hierarchien.

Schritt 4 – Auto-Timeout

Bei wiederholtem Spam kann ein Mitglied mit mindestens **30 Tagen Serverzugehörigkeit** 10 Minuten Timeout erhalten. Ein einzelner Keyword-Treffer eines älteren Kontos reicht dafür nicht. Nach einem weiteren Treffer binnen 15 Minuten kann der Timeout auf **2 Stunden** steigen; Mods bekommen eine Extra-Meldung.

Beobachtungsmodus: Der Bot erkennt, protokolliert und meldet weiterhin. Er löscht, verhängt keinen Timeout und fordert keinen DM-Code an. Admins wechseln den Modus mit **/antispammodus**.

4. DM-Code und Ausnahmen

Codeprüfung: Bei aktiviertem **CAPTCHA_HIGH_RISK** erhält ein verdächtiges junges Konto per DM einen sechsstelligen Code. Der Code gilt 10 Minuten und erlaubt 3 Versuche; nach drei Fehlern folgt eine zehnminütige Sperre. Während einer offenen Prüfung werden weitere Servernachrichten gelöscht. Nach Erfolg entfällt das erhöhte Altersrisiko für 24 Stunden. Der Code belegt nur DM-Zugriff, nicht, dass ein Mensch schreibt.

Ausnahmen: Admins, Mods und Vertrauensrollen sind **nicht automatisch** ausgenommen. Admins können Nutzer, Rollen oder Kanäle mit **/antispamausnahme** für 1 bis 720 Stunden ausnehmen. Ohne Angabe gelten 24 Stunden.

5. Commands & Buttons – Übersicht

Command / Aktion	Wer?	Was passiert?
<code>/antispam</code>	Server verwalten	Zeigt Modus, Einstellungen und heutige Fallzahl.
<code>/antispamstats</code>	Administrator	7-Tage-Grafik, Konten, Auslöser und Maßnahmen.
<code>/antispamfaelle</code>	Server verwalten	Letzte Fälle oder Details zu einer Fall-ID.
<code>/antispamdiagnose</code>	Administrator	Prüft Mod-Kanal und Schreibrechte; optional Testmeldung.
<code>/antispammodus</code>	Administrator	Wechselt zwischen Aktiv und Beobachten.
<code>/antispamausnahme</code>	Administrator	Setzt, listet oder entfernt befristete Ausnahmen.

Mod-Button	Erforderliches Recht	Wirkung
Timeout	Mitglieder moderieren	10 Minuten Timeout.
Kick	Mitglieder kicken	Entfernt das Konto vom Server.
Ban	Mitglieder bannen	Ban bis zur manuellen Aufhebung.
Fehlalarm	Nachrichten verwalten	Markiert den Fall; macht frühere Maßnahmen nicht rückgängig.

6. Leitfaden für Moderatoren

- **Meldung lesen:** Wer schrieb was, wie hoch ist das Risiko, und welche Fall-ID gehört dazu?
- **Kontext prüfen:** Ein neues Konto oder ein einzelnes Keyword kann ein Fehlalarm sein.
- **Entscheidung treffen:** Timeout, Kick oder Ban nur nach Prüfung verwenden; Fehlalarm entsprechend markieren.

Nach dem Klick: Eine erfolgreiche Entscheidung entfernt die Mod-Meldung. Bei einem Fehlschlag bleibt sie standardmäßig stehen. „Fehlalarm“ stellt gelöschte Nachrichten nicht wieder her und beendet keinen bereits verhängten Timeout.

7. Häufige Fragen (FAQ)

Ich habe aus Versehen Spam ausgelöst – was nun?

Melde dich bei der Moderation und nenne Zeitpunkt, Kanal und Nachricht. Ein Mod kann den Fall als **Fehlalarm** markieren. Einen bereits verhängten Timeout muss die Moderation in Discord aufheben.

Warum wurde meine Nachricht gelöscht?

Mögliche Gründe sind mehrfach gleicher Text, ein Keyword-Treffer oder eine offene DM-Codeprüfung. Auch ein einzelnes **free-test-123** kann bei aktiviertem Keyword-Filter gelöscht werden.

Mein Konto ist neu – werde ich deshalb gemeldet?

Nein. Bei Konten unter 4 Tagen steigt nur die Risikoeinstufung. Ohne Spam-Muster oder Wiederholung erfolgt keine Mod-Meldung.

Kann der Bot mich dauerhaft bannen?

Nein. Automatisch sind nur Löschen und unter bestimmten Bedingungen ein Timeout möglich. Kick und Ban brauchen den Klick einer berechtigten Person.

Was bedeutet der Button „Fehlalarm“?

Er dokumentiert diese Mod-Entscheidung und entfernt die Meldung. Er ist keine dauerhafte Whitelist und macht bereits erfolgte Maßnahmen nicht rückgängig.

Warum bekomme ich einen Code per DM?

Ein verdächtiges junges Konto kann um eine sechsstellige Bestätigung gebeten werden. Bei geschlossenen DMs kann der Code nicht zugestellt werden. Wende dich dann an die Moderation.

Wieso sehe ich die Mod-Meldung nicht?

Sie gehört in einen privaten Mod-Kanal. Admins können mit **/antispamdiagnose** den Zugriff und mit **testmeldung:true** eine harmlose Testmeldung prüfen.

Bei Fragen wende dich an die Server-Moderation oder den Server-Administrator.

8. Einrichtung und Statistik für Admins

Bot einrichten

Node.js installieren und im Projektordner **npm ci** ausführen. Die **.env.example** als eigene **.env** ausfüllen. Im Discord Developer Portal **Server Members Intent** und **Message Content Intent** aktivieren. Presence Intent ist nicht nötig.

Bot-Rechte und Start

Der Bot braucht Zugriff auf den privaten Mod-Kanal sowie Rechte für Nachrichten senden/verwalten und Mitglieder moderieren. Kick und Ban benötigen die jeweiligen zusätzlichen Rechte. Seine Rolle muss über den Zielrollen stehen. Danach **node deploy-commands.js** ausführen und den Bot mit **npm start** oder **run-bot.bat** starten. Bei geänderten Slash-Befehlen erneut registrieren.

Fälle und Statistik

/antispamfaelle zeigt bis zu zehn letzte Fälle oder eine Fall-ID im Detail. **/antispamstats** zeigt sieben Tage mit Fällen und verschiedenen auffälligen Konten, bis zu zehn Konten in der Liste sowie Auslöser und Maßnahmen. Das sind Verdachtsfälle, keine bestätigten Scammer. Die Fallzahl ist wegen der Alarm-Drosselung nicht die Zahl aller gelöschten Nachrichten.

Wichtige Einstellungen:

Variable	Wirkung / aktuelle Projektkonfiguration
SPAM_DELETE	Automatisches Löschen; aktuell true .
ML_SPAM_DETECTION	Einfacher Keyword-Filter; aktuell true .
CAPTCHA_HIGH_RISK	DM-Code bei Verdacht und jungem Konto; aktuell true .
SIMILAR_MESSAGE_THRESHOLD	Aktuell 3 ; Programmstandard ohne Eintrag 4.
NEW_ACCOUNT_AGE	Grenze für erhöhtes Risiko; aktuell 4 Tage .
ALERT_COOLDOWN_MS	Drosselung gleicher Meldungen; Standard 120000 ms .
AUTO_TIMEOUT_MEMBER_AGE_MS	Mindestens 30 Tage Serverzugehörigkeit als Standard.
DELETE_MOD_MESSAGE_ON_FAILURE	Nur bei true Meldung nach Fehlschlag entfernen; Standard false .

Daten & Sicherheit: **spam_logs.jsonl** enthält Fälle, Aktionen und bis zu 200 Zeichen des Nachrichtentexts. **antispam-settings.json** speichert Modus und Ausnahmen. Der Mod-Kanal muss privat sein. Ein früher eingechecktes Bot-Token vor einer öffentlichen GitHub-Veröffentlichung erneuern; es kann noch im Git-Verlauf stehen.